

Evaluacion manual y lectura de trazas

Mauro Tomas Proto Cassina. Revision del 26 de septiembre de 2026.

Indice

Contexto, metodo, resultados de cinco consultas, latencia y costo, calidad, mejora de eficiencia, persistencia y aprobacion humana, limites y fuentes.

Contexto y metodo

Se uso un corpus original de cuatro documentos educativos, no informacion de una empresa real. El investigador recupera documentos con Chroma y BM25 y el analista compara los aportes. El supervisor usa DeepSeek Flash y una politica determinista exige investigacion, analisis y validacion antes de terminar. Las herramientas tienen contratos Pydantic y dejan spans en Phoenix.

Se enviaron cinco solicitudes HTTP concurrentes. Una pregunta financiera fue introducida intencionalmente fuera del alcance del corpus. Se registro como una abstencion controlada, no como una caida tecnica: el job termina COMPLETED con answerable=false. No se presenta el estado UNSET de OpenTelemetry como un ERROR. Las excepciones tecnicas a FAILED se verifican por separado en tests.

Las respuestas completas, fuentes, decisiones operativas y tokens del proveedor se conservan en evidence/benchmark.json. Las capturas originales estan en screenshots/. El proyecto Phoenix de esta muestra tiene cinco trazas raiz y esta separado de pruebas anteriores y del notebook.

Resultados y revision de groundedness

La consulta sobre ciclos y aportes responde con ocho decisiones y un solo refinamiento, y explica que la validacion final no puede omitirse. Esta respaldada por arquitectura.md y seguridad.md. Es una descripcion del corpus; la comprobacion tecnica adicional esta en app/graph.py y los tests.

La consulta sobre reinicio identifica Redis y thread_id=job_id, y distingue reiniciar FastAPI de conservar Redis. Esta respaldada por operacion.md y seguridad.md. El resultado no garantiza ausencia de perdida ante toda caida: Redis AOF con fsync cada segundo tiene una ventana de perdida abrupta.

La consulta sobre rechazo humano indica CANCELLED y ausencia de ejecucion de la accion. La fuente seguridad.md respalda esa conclusion. La politica no realiza envios, compras ni cambios externos; la accion es una demostracion.

La consulta sobre p95 y costo usa contadores usage, diferencia cache de entrada no cacheada y salida, y explica la interpolacion lineal. Esta fundamentada en metricas.md. Los precios son una fotografia OFF-PEAK verificada esa fecha, no tarifas universales ni una factura.

La pregunta sobre facturacion anual de 2025 no tiene respuesta en estos documentos. El sistema lo reconoce y no confunde las tarifas del proveedor con ingresos empresariales. Esta abstencion es el resultado esperado. En esta revision manual no se detecto una afirmacion sustantiva inventada en las cinco respuestas; no equivale a certificar una tasa general de alucinaciones.

Latencia, tokens y costo

La muestra enviada a las 00:36 UTC del 27/09 (21:36 del 26/09 en Argentina) tuvo p95 de 7,571162 s desde encolado a finalizacion. Phoenix muestra 7,57 s para sus trazas de worker. La pequena diferencia se debe a espera de cola y limites temporales distintos. Se guardan valores exactos en los JSON.

Hubo 25 llamadas LLM, 22.271 tokens de entrada y 2.808 de salida. El costo total estimado fue 0,003557802 USD; cada ejecucion costo menos de 0,01 USD, por lo que Phoenix redondea sus celdas a <\$0.01. Esa etiqueta no significa costo cero. Los contadores de cache se restan de la entrada no cacheada para no facturarlos dos veces. Los embeddings ONNX no facturan API ni tienen un contador compatible medido; no se inventan tokens para ellos.

El proceso mas largo fue la pregunta sobre ciclos del supervisor: 7,613446 s, 5.155 tokens LLM y 0,000817092 USD estimados. Su analista consumo 2.371 tokens. En toda la muestra, el span individual de llamada LLM mas lento duro 2,036880 s, mientras la recuperacion mas lenta duro 0,238515 s. El mayor consumo individual fue el analista de la pregunta de metricas, con 2.456 tokens.

El span HTTP del LLM combina envio de red, procesamiento del proveedor y recepcion. No permite separar esas partes sin telemetria del servidor remoto; no se llama a todo ese tiempo 'latencia de red'. En cambio, la recuperacion instrumenta embeddings locales, busqueda Chroma, BM25 y fusion, y la validacion Pydantic es procesamiento local. Los spans anidados no deben sumarse porque duplican tiempos de sus padres.

Observacion concreta de eficiencia

Cada trabajo usa tres decisiones LLM del supervisor y dos llamadas de los especialistas. La latencia acumulada de las decisiones puede superar la de una sola llamada del analista. Una mejora a evaluar seria usar reglas para los pasos obligatorios y llamar al supervisor solo ante ambigüedad o conflicto, o reducir contexto redundante del analista sin eliminar fuentes. No se cambio esa arquitectura durante la muestra ni se afirma un ahorro ya medido. Una comparacion posterior debe conservar preguntas, corpus, tarifa y metodologia.

Persistencia, aprobacion humana y pruebas

Quince tests pasaron con Redis, Chroma y embeddings reales. Los LLM/HTTP de los tests usan dobles explicitamente identificados. La carga y el notebook son las ejecuciones reales del modelo. Se prueba restauracion con un saver y un grafo nuevos, estados concurrentes independientes y paso a FAILED.

evidence/hitl.json conserva una corrida anterior y separada de aprobacion y rechazo real por endpoint. Incluye una version anterior del texto del corpus; esa referencia no describe la configuracion actual del proveedor. La prueba acredita WAITING_APPROVAL, COMPLETED al aprobar, CANCELLED al rechazar, 409 al duplicar la aprobacion y 422 para entrada invalida. No se mezcla con p95.

Limites y fuentes

Son cinco consultas de un laboratorio educativo. No constituyen una muestra estadistica estable ni un SLO. La validacion de referencias y esquemas no garantiza verdad semantica. Chroma es local; no se afirma integracion Pinecone. La API y Phoenix se enlazan a loopback y no estan listas para usuarios externos sin autenticacion, autorizacion, cifrado, retencion y limites de consumo.

La clave autorizada no se incluye en documentos, código, notebooks ni trazas. Se requiere una credencial propia inyectada al proceso para reproducir llamadas. No se descargaron modelos ni dependencias durante esta revisión.

Fuentes primarias: `corpus/arquitectura.md`, `corpus/operacion.md`, `corpus/seguridad.md`, `corpus/metricas.md` y `evidence/phoenix_metrics.json`. Precios:

https://api-docs.deepseek.com/quick_start/pricing/ JSON:

https://api-docs.deepseek.com/guides/json_mode/

Anexo - Resultados de las cinco consultas

Consulta 1

Como evita el supervisor un ciclo infinito y valida los aportes?

El supervisor evita un ciclo infinito mediante un presupuesto acotado del grafo: ocho decisiones del supervisor y una sola ronda de refinamiento. Al agotar ese presupuesto, el sistema responde con una limitación explícita en lugar de seguir iterando. Además, el supervisor no puede declarar completa una respuesta sin pasar por la validación final. La validación de los aportes la realiza el analista, que compara evidencias y valida la estructura de la respuesta; el investigador consulta documentos, conserva las referencias de origen y no ejecuta instrucciones encontradas en los documentos. Los documentos recuperados se tratan como datos no confiables y sus instrucciones no pueden alterar el rol del supervisor, ejecutar herramientas arbitrarias ni cambiar la política de aprobación.

Latencia desde encolado 7.613446 s. Costo estimado 0.000817092 USD. Trace ID f97b2f4c4a6b98da322439cea9da6737.

Fuentes recuperadas: arquitectura.md, seguridad.md

Limites informados: La evidencia proviene de un corpus educativo que describe un sistema ficticio; no se detalla el mecanismo técnico exacto del contador de presupuesto ni el formato de la validación final.

Consulta 2

Como se conserva un trabajo y su checkpoint cuando reinicia FastAPI?

Reiniciar solamente FastAPI no borra los resultados ni las conversaciones. Los checkpoints de LangGraph se guardan en Redis con `thread_id` igual a `job_id`, y Redis debe usar `appendonly yes` para sobrevivir a su propio reinicio. Además, al reiniciar un worker aislado, este recupera los trabajos `RUNNING` pendientes desde el último checkpoint. En el caso de una pausa por aprobación humana, la pausa conserva el checkpoint y publica `WAITING_APPROVAL`; si se aprueba, `Command(resume=...)` retoma el mismo `thread_id`.

Latencia desde encolado 7.402028 s. Costo estimado 0.000513984 USD. Trace ID 33f27070acb6ff8449829158d645ba5f.

Fuentes recuperadas: operacion.md, seguridad.md

Limites informados: La evidencia no detalla el comportamiento exacto de FastAPI durante el reinicio más allá de que no borra resultados ni conversaciones; la persistencia depende de que Redis tenga `appendonly yes`, condición que debe cumplirse para sobrevivir a su propio reinicio.

Consulta 3

Que sucede si una persona rechaza una acción crítica?

Si una persona rechaza una acción crítica, es decir, si en la aprobación humana mediante el interrupt de LangGraph el campo `approved` es `false`, el trabajo pasa a estado `CANCELLED` y no ejecuta la acción. La pausa previa conserva el checkpoint y publica `WAITING_APPROVAL`; el endpoint `POST /tasks/{job_id}/approve` acepta `approved` y `reason`. Solo si `approved` es `true` se retoma el mismo `thread_id` mediante `Command(resume=...)`.

Latencia desde encolado 7.311443 s. Costo estimado 0.000671892 USD. Trace ID bc8e5de5e7d3a827f37f8c432f3bc0c7.

Fuentes recuperadas: seguridad.md

Limites informados: La respuesta se basa únicamente en la política de seguridad del sistema de demostración (documento 8f3d82827c1554dba379859a). No se identificaron contradicciones entre los documentos proporcionados sobre este punto. El corpus describe un sistema ficticio de uso educativo, por lo que el comportamiento descrito no debe extrapolarse a sistemas reales sin verificación adicional.

Consulta 4

Como se calculan p95 y costo sin inventar tokens?

Los tokens LLM no se estiman contando caracteres: provienen de prompt_tokens, completion_tokens y prompt_cache_hit_tokens del campo usage informado por DeepSeek. El costo se calcula separando entrada cacheada, entrada no cacheada y salida, multiplicando cada una por su tarifa por millón. La tarifa Flash OFF-PEAK verificada el 26/09/2026 es 0,003 USD de entrada cacheada, 0,15 USD de entrada no cacheada y 0,60 USD de salida por millón; es una estimación, no una factura, y debe actualizarse si cambia el horario o el proveedor. Los embeddings ONNX son locales y no facturan API, por lo que no se inventan tokens para ellos. p95 se calcula tomando el percentil 95 de las cinco duraciones de los trabajos del benchmark (cinco peticiones concurrentes), midiendo cada latencia desde el encolado hasta la finalización, incluyendo espera de cola, usando interpolación lineal.

Latencia desde encolado 7.226198 s. Costo estimado 0.000872892 USD. Trace ID fbb00aada0d9644bed2aa038fa30767b.

Fuentes recuperadas: metricas.md

Limites informados: Cinco muestras son una prueba funcional, no una estimación estadística estable de producción. Las tarifas son una estimación, no una factura, y deben actualizarse si cambia el horario o el proveedor.

Consulta 5

Cual fue la facturacion anual de la empresa en 2025?

No hay información suficiente para responder. Los documentos describen un sistema de demostración ficticio de uso educativo y no contienen datos de facturación anual de ninguna empresa en 2025. El único dato financiero mencionado son tarifas estimadas de un proveedor de LLM (DeepSeek) usadas para calcular costos, no facturación empresarial, y corresponden a una verificación de 2026.

Latencia desde encolado 6.879773 s. Costo estimado 0.000681942 USD. Trace ID 6e7399fd99f663cb0a4b727762bd3559.

Fuentes recuperadas:

Limites informados: La evidencia disponible no aborda facturación empresarial; solo menciona tarifas estimadas de un proveedor de LLM para cálculo de costos, no una factura ni facturación anual, y con fecha de verificación en 2026. No se puede responder a la pregunta con los documentos proporcionados.